



Predicción de cubierta forestal mediante ML



Contenido:

1. Contexto y objetivos del trabajo.
2. Análisis Exploratorio de Datos.
3. Preparación de datos:
 - a. Separación del dataset en *train* y *test*.
 - b. Selección de variables.
4. Modelos:
 - a. *K-Nearest Neighbours*.
 - b. Árboles de Decisión.
 - c. Métodos *Ensemble*: *Random Forest* y *AdaBoost*.
 - d. PCA
5. Conclusiones y continuación del trabajo.

Contexto y objetivo:

- *Comparative accuracies of artificial neural networks and discriminant analysis in predicting forest cover types from cartographic variables (1999).*
 - Desarrollo de modelos capaces de predecir las especies de árbol que forman distintos bosques dentro del *Roosevelt National Forest* en Colorado.




Fig. 1. Study area location map.





Contexto y objetivo:

- Objetivos del trabajo:
 - a. Desarrollar modelos mínimamente precisos.
 - b. Superar la capacidad predictiva de los modelos desarrollados en el artículo.

	precision	recall	f1-score	support
1	0.78	0.79	0.79	209680
2	0.87	0.72	0.79	281141
3	0.81	0.88	0.84	33594
4	0.27	0.98	0.42	587
5	0.26	0.97	0.41	7333
6	0.58	0.91	0.71	15207
7	0.59	0.98	0.74	18350
accuracy			0.77	565892
macro avg	0.59	0.89	0.67	565892
weighted avg	0.81	0.77	0.78	565892




Análisis exploratorio de datos:

- Contenido del dataset:
 - a. Variables geográficas pertenecientes a parcelas de 30 m x 30 m en el *Roosevelt National Forest*.
- Características:
 - a. 581012 registros, 0 nulos.
 - b. 55 columnas.
 - 10 variables numéricas continuas.
 - 2 variables categóricas (**one-hot encoded**): 4 + 40 columnas.
 - c. Más de 0.25 GB.

Análisis exploratorio de datos:


- Variable a predecir: *Forest Cover Type*.
 - a. Variable **categorica**, 7 clases posibles.
- Estamos ante un problema de clasificación.




Análisis exploratorio de datos:



Wilderness Area Distribution




Análisis exploratorio de datos:




Análisis exploratorio de datos:



Cover Type: Rawah




Cover Type: Neota




Análisis exploratorio de datos:

Cover Type: Comanche Peak



Cover Type: Coche la Poudre





Preparación de datos:


- Separación de *train* y *test*:
 - El dataset contiene los datasets del *train* y *test* ordenados:
 - Primeros 11340 registros: *train*.
 - Sigüientes 3780 registros: *validation*.
 - Registros restantes: *test*.
 - Problema de clasificación:
 - Interesa que *train* contenga la misma cantidad de valores de cada categoría.
 - Los datasets *train* y *validation* están uniformemente repartidos.



Preparación de datos:


- Cantidad de variables utilizadas. Criterio seguido en el artículo:
 - Solo las variables numéricas, sin las variables categóricas: **10 columnas** + target.
 - Todas las variables: 54 columnas + target.
- Se ha optado por emplear todas las columnas:
 - *Random Forest*, $n_estimators = 100$, $max_depth = 15$
 - *Test Accuracy*:
 - Solo variables numéricas: 68%.
 - Todas las variables: 70%.

Modelos: *K-Nearest Neighbours*



Modelos: *Decision Tree*

- Pieza básica de los modelos *ensemble* entrenados en la siguiente sección.
- 2 *Grid Search CV* consecutivos:
 - Para evitar overfitting:
 - $min_samples_leaf = 5$
 - Parámetros óptimos:
 - $max_depth = 19$
 - $criterion = gini$
- Resultados:
 - **Score:** 71.39 %
 - **Test accuracy:** 66.2 %.



Modelos ensemble: *Random Forest*



- *Grid Search* para encontrar la mejor configuración de parámetros:
 - *n_estimators* = 150
 - *max_depth* = 25
 - *min_samples_leaf* = 10
- Resultados:
 - **Score:** 77 %
 - **Accuracy:** 73.5 %


Modelos *Ensemble*: AdaBoost



- Considerablemente más pesado que los modelos *Random Forest*.
 - Un parámetro más sobre el que iterar: *learning rate*.
 - Cómputo pesado, solo se ha realizado un *Grid Search*. Es necesario realizar otro para afinar aún más los parámetros.
- *Grid Search*:
 - Aún así, parámetros óptimos:
 - *n_estimators* = 220
 - *max_depth* = 20
 - *learning_rate* = 0.6.
- Resultados:
 - **Score:** 80.7 %
 - **Accuracy:** 77.5%

Modelos no supervisados: PCA

- El dataset contiene muchas dimensiones, conviene probar a deshacerse de algunas de ellas.
- Se han calculado los **40 componentes principales** (para 54 columnas).
- Se ha probado a usar versiones reducidas del dataset con 10, 20, 30 y 40 PCs.
 - Modelos **Random Forest** con valores próximos a los óptimos (RF no se ve *tan* afectado por la alta dimensionalidad).





Resultados:

Autor(es)	Tipo de Modelo	Test Accuracy
Artículo Científico	<i>Discriminant Analysis</i>	58 %
	<i>Artificial Neural Network</i>	70%
Antton	<i>K-Nearest Neighbours</i>	approx 68 %
	<i>Decision Tree</i>	66.2 %
	<i>Random Forest</i>	73.5 %
	<i>AdaBoost</i>	77.5 %

Conclusiones:

- Posibles mejoras:
 - Profundizar más en el Feature Engineering.
 - Probar a construir una red neuronal.

